

Bola de Radio Mínimo mediante Programación Cuadrática Convexa

Darien Mandujano Zubieta
Reporte Final

18 de diciembre de 2025

Resumen

En este trabajo se analiza la eficiencia computacional de reformular el problema geométrico de la Bola de Radio Mínimo (Smallest Enclosing Ball, SEB) como un problema de Programación Cuadrática (QP) convexo, siguiendo la metodología propuesta por Schönherr (2002). Se comparan dos solvers de primer orden, **OSQP** (basado en ADMM) y **SCS** (basado en Splitting Cónico), variando la dimensión del problema desde $d = 2$ hasta $d = 30$ con $n = 50$ puntos fijos. Los resultados experimentales demuestran que, contrario a la intuición de la maldición de la dimensionalidad, el problema se vuelve numéricamente más estable en altas dimensiones. Asimismo, se reporta un tiempo de cómputo polinomial que se mantiene por debajo de 1,2 ms en el peor caso, validando la formulación para aplicaciones en tiempo real.

1. Introducción

El problema de encontrar la esfera más pequeña que encierra un conjunto de puntos $P = \{p_1, \dots, p_n\} \subset \mathbb{R}^d$ es un problema fundamental en la geometría computacional. Sus aplicaciones se extienden más allá de la teoría pura, siendo un componente crítico en:

- **Aprendizaje Automático:** En algoritmos como *Support Vector Data Description* (SVDD) para detección de anomalías y clasificación de una clase.
- **Computación Gráfica:** Para la detección de colisiones mediante volúmenes envolventes (Bounding Volumes).
- **Análisis de Datos:** Como medida robusta de dispersión y detección de outliers.

Si bien la formulación geométrica intuitiva involucra minimizar r^2 sujeto a $\|p_i - c\|^2 \leq r^2$, este planteamiento no es convexo en su forma original. Schönherr [2] demostró que una transformación de variables permite plantearlo como un Programa Cuadrático (QP) convexo estándar, garantizando la unicidad de la solución. El presente reporte evalúa la robustez numérica de esta formulación.

2. Metodología

2.1. Formulación Matemática

El problema primal se define como:

$$\min_{c, r} r^2 \quad \text{s.a.} \quad \|p_i - c\|^2 \leq r^2, \quad \forall i = 1, \dots, n \quad (1)$$

Para eliminar la no convexidad, expandimos la norma euclidiana en la restricción:

$$p_i^T p_i - 2p_i^T c + c^T c \leq r^2 \quad (2)$$

Reordenando los términos, introducimos la variable auxiliar $K = r^2 - c^T c$. Esto nos permite linealizar las restricciones y obtener una función objetivo cuadrática convexa:

$$\min_{c, K} c^T c + K \quad (3)$$

$$\text{s.a.} \quad 2p_i^T c + K \geq \|p_i\|^2, \quad \forall i = 1 \dots n \quad (4)$$

El Hessiano respecto a las variables (c, K) es $H = \text{diag}(2, \dots, 2, 0)$, el cual es semidefinido positivo, asegurando que cualquier mínimo local es un mínimo global [1].

2.2. Diseño Experimental

La implementación se realizó en Python utilizando la interfaz de modelado CVXPY.

- **Datos:** Se generaron nubes de puntos con distribución normal estándar $N(0, I)$ para $d \in [2, 30]$.
- **Validación (Sanity Check):** Se generaron puntos aleatorios sobre la superficie de la esfera unitaria en \mathbb{R}^3 . El algoritmo recuperó exitosamente el centro en el origen y radio unitario (ver Fig. 1).
- **Solvers:** Se compararon OSQP y SCS, ejecutando 20 pruebas independientes por dimensión para obtener significancia estadística.

3. Resultados

A continuación se presenta el resumen estadístico del desempeño de ambos solvers. Los tiempos de cómputo son del orden de milisegundos.

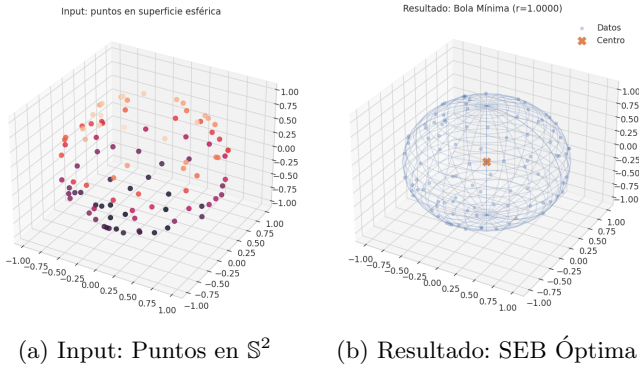


Figura 1: Validación Visual en \mathbb{R}^3 . El solver recupera correctamente la esfera unitaria ($r \approx 1,0, c \approx 0$).

Tabla 1: Desempeño (Promedio \pm Desviación Estándar)

Dim	Solver	Tiempo (s)	Iteraciones
2	OSQP	0,0047 \pm 0,0026	1142 \pm 440
	SCS	0,0026 \pm 0,0070	403 \pm 771
10	OSQP	0,0005 \pm 0,0002	138 \pm 66
	SCS	0,0004 \pm 0,0001	106 \pm 17
30	OSQP	0,0011 \pm 0,0001	80 \pm 13
	SCS	0,0005 \pm 0,0001	55 \pm 10

4. Discusión

4.1. Anomalía Geométrica en Baja Dimensión

La Figura 3 revela una diferencia drástica de desempeño en $d = 2$. OSQP requirió > 1000 iteraciones promedio. **Análisis:** Con $n = 50$ puntos en el plano, la densidad geométrica es alta ($n \gg d$). Esto genera un fenómeno de “crowding”, donde muchas restricciones son casi redundantes o linealmente dependientes. El algoritmo ADMM (usado por OSQP) tiende a oscilar en presencia de múltiples restricciones activas degeneradas. SCS, al usar optimización cónica primal-dual, demostró mayor robustez en este régimen saturado.

4.2. Concentración de la Medida en Alta Dimensión

Contrario a la “maldición de la dimensionalidad”, resolver el problema en $d = 30$ resultó numéricamente más sencillo que en $d = 2$. **Explicación:** Este comportamiento es consistente con el fenómeno de *concentración de la medida* en espacios de alta dimensión. Al aumentar d , los puntos distribuidos normalmente tienden a concentrarse en una capa delgada cerca de la superficie de la esfera envolvente. Esto hace que la distinción entre puntos activos (en la frontera) e inactivos (interiores) sea numéricamente más nítida, facilitando la convergencia rápida de los algoritmos de punto interior y splitting.

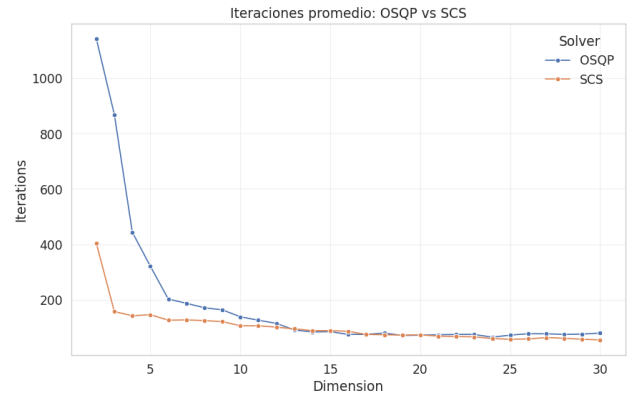


Figura 2: Iteraciones promedio vs. Dimensión. Se observa una clara estabilización y reducción del costo computacional en alta dimensión.




Figura 3: Diferencia $\Delta = \text{Iter}_{SCS} - \text{Iter}_{OSQP}$. Valores negativos indican ventaja de SCS en $d = 2$. Para $d \geq 10$, la diferencia es marginal.

5. Conclusión

La reformulación convexa de Schönherr es altamente eficiente y escalable. Aunque se detectó sensibilidad a la densidad geométrica en dimensiones bajas para el solver OSQP, ambos métodos convergieron en tiempos despreciables (< 2 ms) para $d \geq 10$. La estabilidad observada en altas dimensiones valida esta metodología para aplicaciones modernas de ciencia de datos donde d es elevado.

Referencias

- [1] Nocedal, J., & Wright, S. (2006). *Numerical Optimization*. Springer Science & Business Media.
- [2] Schönherr, S. (2002). *Quadratic Programming in Geometric Optimization: Theory, Implementation, and Applications*. Diss. ETH No. 14738.